

1강 Introduction

머신러닝의 정의: 데이터 기반의 알고리즘을 만드는 분야

데이터로부터 알고리즘을 만드는 과정 : Learning(training)

모델이 만들어지고 실제로 데이터에 적용하는 과정: Inference(test)

모든 머신러닝은 Learning과 Inference가 분리된 2 step process를 갖는다.

Two steps of Machine Learning

Training(learning) : With training data, extract a model(approximate input-output relationship(function))

Test(inference): With the trained model, apply the model in practice with test data, and measure the performance

Train, Test 용 데이터를 분리하는 과정이 절대적으로 필요하다

Test 과정에 사용될 데이터가 명확히 분리되지 않으면 cheating이기 때문

Classification

학습시키려는 모델 알고리즘이 input의 종류에 상관없이 output이 유한개의 class에 속하는 경우

Regression

Machine Learning : 3 diff types

1. Supervised Learning
2. Unsupervised Learning
3. Reinforcement Learning

교수님께서는 지도 학습 vs 비지도 학습으로 분류하는 것이 맞다고 하심

지도학습 vs 비지도학습 = Ground Truth의 유무

지도 학습: 학습을 진행하는 과정에서 **정답이 있음**, 예시를 주고 학습함

비지도 학습: 학습을 진행하는 과정에서 **정답이 없음**, 예시를 주지 않아도 학습

머신러닝에서 정답, 레이블 == 통계학에서 Ground Truth

supervised learning

Supervised Learning

- **Most successful so far**

- Learn $p(y|x)$ where x is data, and y is label.
- Classification
- Regression
- Strikingly successful so far
 - Better (?) than humans in image classification accuracy: Imagenet competition (ILSVRC)
 - Alphago
 - Speech recognition: Amazon's Alexa
 - Language translation: Google's machine translation

단순한 확률이 아닌 어떤 x 가 들어갔는지에 대한 조건부확률

주어진 x 에 대해 모든 가능한 y 에 대해 가능한 확률 값 y 를 벡터 형태로 뽑아내는 과정

조건부 확률을 배우는 과정이 supervised learning이다. -> 확률 이론적 입장

Unsupervised Learning

Unsupervised Learning

- **Learn $p(x)$ without labels, where x is the data.**
 - Clustering: K-means algorithm
 - Dimensionality reduction: PCA
 - Restricted Boltzman Machine (RBM)
 - Bipartite graph (Markov random field)
 - Autoencoder
 - Feature extraction (compression in information theory)
 - Variational autoencoder
 - Generative AI
 - GAN, Diffusion models
 - Self-supervised learning: Dinov2, SAM, etc
 - Transformers: chatGPT, etc.

clustering = 기본적인 unsupervised learning 의 방법

PCA = clustering을 조금 더 잘하는 방법론, 선형대수의 아이겐벨류, 아이겐벡터가 있는데, 아이겐벨류 값이 큰 것들을 뽑아 전체 데이터셋을 다룬다

ML model's weak points

머신러닝 모델들은 완벽하지 않다. 근사치를 제공할뿐이다.

결과 값을 해당 결과가 나올 확률로 출력하는 것이 바람직한 방식이다.

예시) 멀리서 찍은 사과와 토마토는 classification 임에도 무엇이 맞다고 확신할 수 없음. 이에 사과일 확률, 토마토일 확률을 제공하는 것이 더 바람직함. 머신러닝 모델을 통해 나온 결과들 또한 이와 유사함

모델을 학습시킨다는 것

x, y의 함수관계를 학습시키는 것이 아님

x와 x에 해당하는 y가 나올 확률간 매핑을 시키는 것
Vector output을 가지는 함수를 학습시키는 과정이다.

지도 학습과 비지도 학습으로 분류를 하고 (지도학습과 비지도학습은 둘 다 학습 데이터가 있는 상황을 가정함)
강화 학습과 비강화 학습으로 분류를 하는 것이 더 올바른 분류에 가깝다

Reinforcement Learning

Reinforcement Learning

- Similar to how a child learn from parents
- What is different from other machine learning paradigms?
 - There is no supervisor, only a reward signal
 - Feedback is delayed, not instantaneous
 - Time really matters (sequential, non i.i.d data)
 - Agent's actions affect the subsequent data it receives
- Examples of Reinforcement Learning
 - Robotics in general
 - Fly stunt manoeuvres in a helicopter
 - Make a humanoid robot walk
 - Games in general
 - Play many different Atari games better than humans
 - Play Go better than humans
 - Manage an investment portfolio

강화 학습과 비강화 학습의 차이: 학습 데이터를 미리 모아두는가 or 필요할 때마다 새로 모을 것인가

강화 학습 : 데이터를 필요할 때마다 조금씩 모으는 학습론 (배치를 필요할 때마다 모을 것인가?)

비강화 학습 : 데이터를 한 번에 모아두고 학습을 시작(배치를 미리 모아두고 학습을 시작할 것인가?)

통계학의 관점에서 미리 모아놓은 데이터 = 배치

강화 학습의 조금 더 엄밀한 정의

환경 = 데이터를 모을 수 있는 대상

에이전트 = 데이터를 모으는 역할을 하는 알고리즘(일반적으로 알고리즘을 강화학습에서 에이전트라고 지칭함)

액션 = 환경에 영향을 미치는 과정

리워드 = 환경으로부터 피드백을 받는 과정(일반적으로 스칼라 값), 리워드는 GT와는 다르다

에이전트가 필요에 따라 환경과 상호작용하며, sequential한 learning을 하는 것

조금씩 데이터를 업데이트해가는 방법론

강화학습은 리워드와 관계없이 환경과 지속적인 상호작용을 하며 데이터를 모아나가는 학습

따라서 모든 머신러닝은 강화학습적 방법론과 비강화학습적 방법론이 존재한다.(이분법적으로 설명이 가능하다)

sequential 한 learning을 하는지 안하는지에 따라 강화학습과 비강화학습이 나뉘는 것

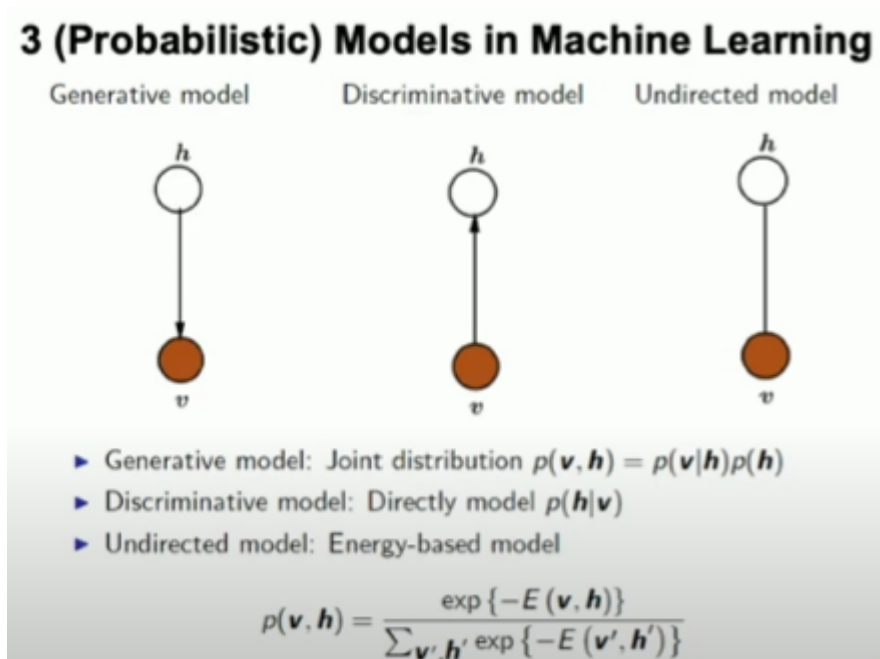
대부분의 biological한 시스템에서 학습하는 과정은 강화학습과 유사함

시행착오에 의한 학습(trial & error learning)

움직임과 밀접한 연관이 있음, 로보틱스에서 중요하게 쓰임

추천 시스템 또한 강화학습 기반 알고리즘이 적용됨

Probabilistic Models in Machine Learning



위쪽의 하얀 노드 = latent variable

h = hidden variable

v = input variable

latent space = 주요한(큰) eigenvalue, eigenvector를 베이스로 삼는 데이터 스페이스의 서브 스페이스

latent variable = 그 서브 스페이스의 변수들

low dimensional space(latent variable) 에서 high dimensional space로 데이터를 매핑하는 과정(직관적으로 쉽게 표현하면)

엄밀한 표현 = sampling 한다

GAN, diffusion 모델의 input은 노이즈. 여기서 latent variable = noise, 출력으로 나오는 데이터가 image(input data)

Generative model 의 목적 : Joint distribution 을 학습하는 것

generative model에서 이미지를 생성하기 위해 프롬프트를 작성하는데, 이 프롬프트가 여기서 h에 해당하여 무수히 많은 경우의 수 중 h로 들어간 프롬프트에 해당하는 것과 유사한 이미지를 결과로 내어줌

Discriminative model은 supervised learning과 동일

GT를 넣어 학습해서 판별

Resurgence of Deep Learning

Resurgence of Deep Learning

기존 인공신경망 모델의 단점 극복

- 최적화 과정에서 local minima에 빠지는 문제 극복(Hinton, 2004)
 - Restricted Boltzmann machine(RBM)을 이용하여 Parameter를 pre-training으로 해결함
- 학습데이터에 맞춰서 학습되는 과적합(Overfitting) 문제 해결(Hinton, 2012)
 - 드롭아웃(Dropout) 알고리즘으로 과적합 문제 해결

하드웨어의 발전

- 강력한 성능의 GPU(graphics processing unit) 출현
 - 복잡한 매트릭스와 벡터 계산이 존재해 있는 경우 몇 주 ~ 몇 달 걸리던 작업을 며칠 사이로 줄이는 등 최고의 성능(GeForce GTX Titan의 경우 계산이 가능한 CUDA core가 무려 2688개 존재)을 발휘함
- 클라우드 서비스
 - 상대적으로 저렴한 비용(종량제)으로 슈퍼 컴퓨터급의 연산장치 및 저장장치를 활용, 기업의 각종 정보처리를 효율적으로 수행할 수 있는 인프라가 확대됨

Big Data 출현


- Big Data 출현
 - 인터넷, SNS 데이터의 폭발적 증가
 - 제 4 산업혁명(IoT 등)의 시작
 - 산업의 융복합, IT와 전통 서비스의 Convergence 등으로 인해, 기존에 경험하지 못했던 대용량 데이터 처리 및 분석의 필요성 대두

딥러닝 학습이 잘 이루어지지 않았던 이유 = 가중치 초기화를 잘 하지 않았어서

History of Machine Learning

- 1958: Perceptron (Rosenblatt)
- 1982: Self-organizing maps (Kohonen)
- 1983: Boltzman machine (Hinton and Sejnowski)
- 1984: PAC learning theory (Valiant)
- 1986: Backpropagation (Rumelhart, Hinton, and Williams)
- 1992: Support vector machine (Boser, Guyon, and Vapnik)
- 1995: Statistical learning theory (Vapnik)
- 1997: Long Short-Term Memory (LSTM) Recurrent Neural Networks (RNN) (Hochreiter and Schmidhuber)
- 1998: Convolutional Neural Networks (LeCun)
- 2004: Deep learning resurrection
 - 2004: RBM to Deep Neural Networks (Hinton)
 - 2012: Dropout to Deep Neural Networks (Hinton)
- 2012: Alex nets (Alex Krizhevski): super-human performance in object recognition
- 2014: Gated Recurrent Units (GRU) RNN (Cho)
- 2016: Alphago (Google Deepmind) vs Sedol Lee: super-human performance in game
- 2014: GAN (I. Goodfellow): photo-realistic generative model
- 2017: Attention (A. Vaswani): Transformer for NLP
- 2018: BERT (J. Devlin): Pre-training + fine-tuning
- 2020: GPT-3 (OpenAI): Autoregressive language model, 1st human-like text generation
- 2022: DALL-E 2 (OpenAI): generate digital images from natural language description

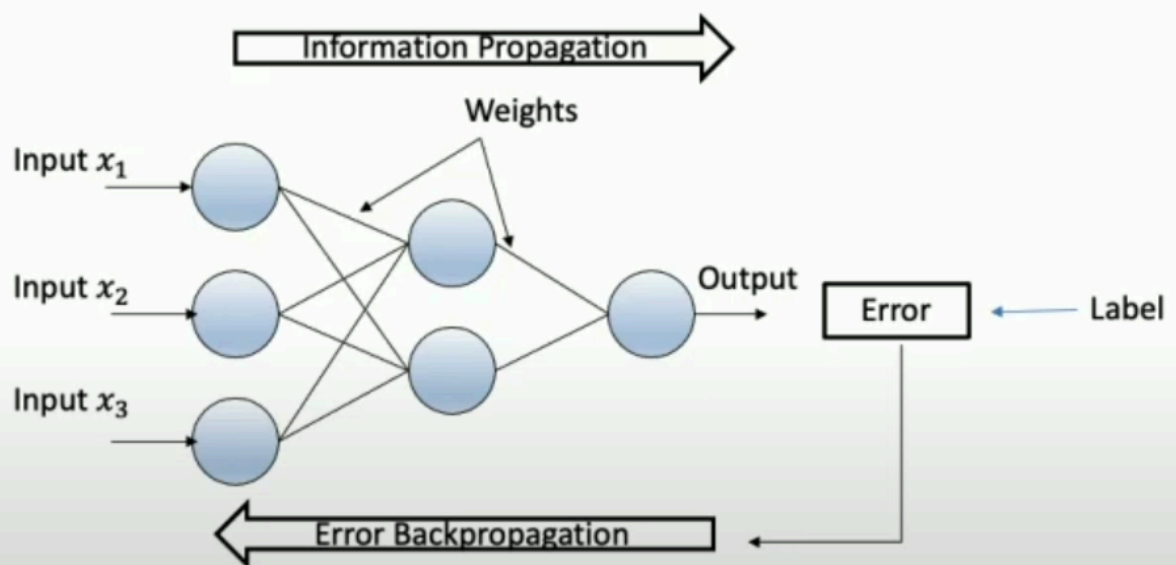
Introduction to Neural Networks



Neural Network : Mathematically Modelling of Human Neurons

Introduction to Neural Networks

Training : Repetitive Error Correction!



Transformer = 현존하는 거의 모든 생성형 AI의 구조